

Оршил

Энэ даалгаврын хүрээнд k-means clustering аргыг ашиглан худалдааны төвийн хэрэглэгчдийг зан төлөвийн хэв маягаар нь сегментчилээ. Өгөгдлийг судалж. Elbow аргаар тохиромжтой кластерийн тоог сонгож, sklearn сангийн Kmeans ашиглан кластерчлал хийж үр дүнг тайлбарлан бичлээ.

EDA

Энэхүү судалгаанд Mall Customers өгөгдлийг ашиглан хэрэглэгчдийн зан төлөвийг судалсан. Өгөгдөл нь нийт 200 мөр, 5 баганаас бүрдсэн бөгөөд хэрэглэгчдийн нас, хүйс, жилийн орлого болон худалдан авалтын идэвхийн оноог агуулдаг. Өгөгдлийг шалгахад алдагдсан утга (missing value) илрээгүй бөгөөд бүх баганууд зөв өгөгдлийн төрөлтэй байсан.

```
Shape: (200, 5)
```

```
Data types:
```

CustomerID	int64
Gender	object
Age	int64
Annual Income (k\$)	int64
Spending Score (1-100)	int64
dtype:	object

```
Missing values:
```

CustomerID	0
Gender	0
Age	0
Annual Income (k\$)	0
Spending Score (1-100)	0
dtype:	int64

Хэмжээ, бүтэц, төрөл

Тоон хувьсагчдын статистик үзүүлэлтүүдийг (mean, median, standard deviation, minimum, maximum, quartiles) тооцоолж судлахад хэрэглэгчдийн нас ихэвчлэн 20-40 насны хооронд

төвлөрсөн байна. Жилийн орлогын хувьд хэрэглэгчдийн орлого харьцангуй өргөн тархалттай бөгөөд бага болон өндөр орлоготой хэрэглэгчид аль аль нь байна. Харин spending score буюу худалдан авалтын идэвхийн оноо ихэвчлэн 40-60 орчимд төвлөрсөн байгаа нь ихэнх хэрэглэгчид дундаж хэрэглээтэй байгааг харуулж байна.

	Age	Annual Income (k\$)	Spending Score (1-100)
count	200.000000	200.000000	200.000000
mean	38.850000	60.560000	50.200000
std	13.969007	26.264721	25.823522
min	18.000000	15.000000	1.000000
25%	28.750000	41.500000	34.750000
50%	36.000000	61.500000	50.000000
75%	49.000000	78.000000	73.000000
max	70.000000	137.000000	99.000000

Median:

Age 36.0

Annual Income (k\$) 61.5

Spending Score (1-100) 50.0

dtype: float64

Тоон багануудын статистик

Хүйсийн тархалтыг харахад эрэгтэй болон эмэгтэй хэрэглэгчдийн тоо харьцангуй ойролцоо байсан бөгөөд өгөгдөлд хүйсийн хувьд тэнцвэртэй байдал ажиглагдсан.

Gender count:

Gender

Female 112

Male 88

Name: count, dtype: int64

Gender ratio:

Gender

Female 56.0


Male 44.0

Name: proportion, dtype: float64

Gender Тархалт


Дүрслэлүүд

Histogram графикаар Age, Annual Income (k\$) болон Spending Score (1-100) хувьсагчдын тархалтыг харууллаа. Насны тархалтаас харахад хэрэглэгчдийн ихэнх нь 20-40 насны хооронд байна. Жилийн орлогын тархалт харьцангуй жигд боловч дунд орлоготой хэрэглэгчид илүү их байгааг харж болно. Spending score буюу худалдан авалтын идэвхийн оноо 40-60 орчимд төвлөрсөн байгаа нь ихэнх хэрэглэгчид дундаж хэрэглээтэй байгааг илэрхийлж байна.



Histogram-үүд


Boxplot графикаар хувьсагч бүрийн тархалт болон боломжит outlier утгуудыг харуулсан. Насны тархалт харьцангуй төвлөрсөн бөгөөд маш их хэт утгууд ажиглагдсангүй. Жилийн орлогын хувьд утгууд илүү өргөн тархалттай байгаа нь хэрэглэгчдийн орлогын ялгаа их байгааг харуулж байна. Spending score нь дунд орчимд төвлөрсөн тархалттай байгаа бөгөөд хүчтэй outlier ажиглагдсангүй.



Boxplot


Correlation heatmap нь тоон хувьсагчдын хоорондын шугаман хамаарлыг харуулдаг. Энэхүү графикаас харахад Age, Annual Income, болон Spending Score хувьсагчдын хооронд хүчтэй

корреляци ажиглагдсангүй. Энэ нь эдгээр хувьсагчид хоорондоо хүчтэй хамааралгүй бөгөөд хэрэглэгчдийн зан төлөвийг ялгахад тус тусдаа мэдээлэл агуулж байгааг харуулж байна.



Correlation Heatmap

Pairplot нь хувьсагч бүрийн тархалт болон хоорондын хамаарлыг нэг дор харуулсан. Диагональ хэсэгт хувьсагч бүрийн тархалт (histogram) харагдаж байгаа бол бусад хэсэгт scatter plot-аар хувьсагчдын хос хамаарлыг үзүүлсэн. Annual Income болон Spending Score хоорондын графикаас тодорхой бүлэглэлүүд ажиглагдаж байгаа нь хэрэглэгчдийг кластер болгон сегментчилэх боломжтойг харуулж байна.



Pairplot

EDA Дүгнэлт

Өгөгдөл нь 200 мөр, 5 баганатай бөгөөд алдагдсан утга байхгүй байна. Тоон багануудын статистик үзүүлэлтээс харахад хэрэглэгчдийн нас, жилийн орлого болон худалдан авалтын идэвхийн оноо нь нэлээд ялгаатай тархалттай байна. Histogram болон boxplot графикуудаас зарим тархалтын хэлбэрүүд ажиглагдсан боловч хүчтэй outlier их ажиглагдсангүй.

Pairplot болон correlation heatmap-аас харахад Annual Income (k\$) болон Spending Score (1-100) хувьсагчид хэрэглэгчдийн зан төлөвийг ялгахад чухал шинж байж болох нь ажиглагдсан. Иймээс кластерчлал хийхдээ эдгээр feature-үүдийг ашиглахаар сонгов.


Elbow Method

Annual Income (k\$) болон Spending Score (1-100) 2 feature-ийг ашиглав.

```
X = df[["Annual Income (k$)", "Spending Score (1-100)"]]  
X.head()  
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```

Стандарт scaler ашиглаж ижилсүүлэв

Elbow plot график нь кластерын тоо (K) болон inertia (within-cluster sum of squares) хоорондын хамаарлыг харуулдаг. Графикаас харахад inertia утга K=5 хүртэл огцом буурч, түүнээс хойш бууралт удааширч байна. Энэ нь K=5 орчимд “тохойн цэг” үүсэж байгааг харуулж байгаа тул хамгийн тохиромжтой кластерын тоог K=5 гэж сонгосон.



Elbow method

Миний шалгалтаар $K = 5$ орчимд тохойн цэг хамгийн тод харагдаж байна. Мөн энэ өгөгдөл дээр 5 кластер сонгоход сегментүүд бизнес утгаар тайлбарлахад ойлгомжтой байдаг. Иймээс хамгийн тохиромжтой кластерийн тоо 5 гэж сонгож байна.

	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)	Cluster
0	1	Male	19	15	39	4
1	2	Male	21	15	81	2
2	3	Female	20	16	6	4
3	4	Female	23	16	77	2
4	5	Female	31	17	40	4

KMeans загвар байгуулах

Scatter plot графикаар Annual Income болон Spending Score ашиглан K-means алгоритмаар гарсан кластеруудыг дүрслэн харуулсан. Өнгө бүр нь өөр өөр хэрэглэгчийн сегментийг илэрхийлж байгаа бөгөөд хар X тэмдэг нь кластер бүрийн төвийг (centers) илэрхийлнэ. Графикаас харахад хэрэглэгчид орлого болон худалдан авалтын идэвхийн түвшнээрээ хэд хэдэн ялгаатай бүлэгт хуваагдаж байгаа нь кластерчлал амжилттай хийгдсэнийг харуулж байна.



кластеруудыг дүрслэхүй

Кластер бүрийн дундаж нас, жилийн орлого болон spending score-ийг тооцоолж хэрэглэгчдийн сегментүүдийг тодорхойлов. Үр дүнгээс харахад зарим кластерууд өндөр орлоготой боловч бага хэрэглээтэй, зарим нь бага орлоготой боловч өндөр хэрэглээтэй зэрэг ялгаатай зан төлөвтэй хэрэглэгчдийг илэрхийлж байна. Ийм сегментчилэл нь маркетингийн стратеги боловсруулахад чухал ач холбогдолтой.

	Age	Annual Income (k\$)	Spending Score (1-100)	Count	Segment Name
Cluster					
0	42.72	55.30	49.52	81	Бага орлоготой - бага хэрэглээтэй
1	32.69	86.54	82.13	39	Өндөр орлоготой - өндөр хэрэглээтэй
2	25.27	25.73	79.36	22	Бага орлоготой - өндөр хэрэглээтэй
3	41.11	88.20	17.11	35	Өндөр орлоготой - бага хэрэглээтэй
4	45.22	26.30	20.91	23	Бага орлоготой - бага хэрэглээтэй

Кластер бүрийн профайл

Тухайн кластерчлалын чанарыг үнэлэхийн тулд **Silhouette Score** тооцоолсон. Үр дүнд:

Silhouette Score = 0.555 гарсан байна.

Silhouette score нь -1-ээс 1 хүртэл утгатай байдаг бөгөөд:

- 0.7 - 1.0 > маш сайн кластер
- 0.5 - 0.7 > сайн кластер
- 0.25 - 0.5 > дунд зэрэг
- 0.25 > сул кластер

Манай тохиолдолд **0.555** гарсан нь кластерууд хоорондоо нэлээд сайн ялгарсан бөгөөд K-means алгоритм хэрэглэгчдийг боломжийн сайн сегментчилж чадсаныг харуулж байна.

Silhouette Score: 0.555
Final chosen K = 5

Cluster Centers:

	Annual Income (k\$)	Spending Score (1-100)
0	55.296296	49.518519
1	86.538462	82.128205
2	25.727273	79.363636
3	88.200000	17.114286
4	26.304348	20.913043

Cluster Profile:

	Age	Annual Income (k\$)	Spending Score (1-100)	Count	\
Cluster					
0	42.72	55.30	49.52	81	
1	32.69	86.54	82.13	39	
2	25.27	25.73	79.36	22	
3	41.11	88.20	17.11	35	
4	45.22	26.30	20.91	23	

Segment Name

Cluster

0	Бага орлоготой - бага хэрэглээтэй
1	Өндөр орлоготой - өндөр хэрэглээтэй
2	Бага орлоготой - өндөр хэрэглээтэй
3	Өндөр орлоготой - бага хэрэглээтэй
4	Бага орлоготой - бага хэрэглээтэй

Silhouette Score

Дүгнэлт


Энэхүү ажилд Mall Customers өгөгдөл дээр K-means clustering ашиглан хэрэглэгчдийг сегментчиллээ. Эхлээд өгөгдлийн бүтэц, статистик үзүүлэлтүүд болон тархалтыг судалж, алдагдсан утга байхгүйг тогтоосон. Мөн Annual Income (k\$) ба Spending Score (1-100) нь сегмент ялгахад хамгийн ойлгомжтой feature болох нь дүрслэлүүдээс харагдсан.

Elbow method ашиглан кластерын тоог сонгоход $K=5$ нь хамгийн тохиромжтой гэж үзэгдсэн. Учир нь inertia утга $K=5$ хүртэл огцом буурч, түүнээс хойш бууралт удааширсан нь “тохойн цэг” тодорхой байгааг харуулсан. Энэ K утгаар KMeans загвар сургахад хэрэглэгчид орлого болон хэрэглээний идэвхээрээ ялгаатай 5 бүлэгт хуваагдсан.



Кластерын профайлаас өндөр орлоготой ба өндөр хэрэглээтэй, өндөр орлоготой ч бага хэрэглээтэй, бага орлоготой ч өндөр хэрэглээтэй зэрэг ялгаатай сегментүүд гарч ирсэн. Энэ нь худалдааны төвийн маркетинг, хөнгөлөлт, урамшууллын стратеги боловсруулахад хэрэгтэй мэдээлэл болж чадна. Тухайлбал өндөр орлоготой-өндөр хэрэглээтэй сегмент нь premium саналд тохиромжтой бол өндөр орлоготой-бага хэрэглээтэй сегментэд идэвхжүүлэх маркетинг хэрэгтэй байж болно.

Гауссын Микстюр ашигласан нь

GMM - ийн хамгийн тохиромжтой кластерийн тоог олох нь



GMM - ээр аймаглал хийсэн нь.



Харьцуулалт

	Age	Annual Income (k\$)	Spending Score (1-100)	Count	Segment Name
Cluster					
0	42.72	55.30	49.52	81	Бага орлоготой - бага хэрэглээтэй
1	32.69	86.54	82.13	39	Өндөр орлоготой - өндөр хэрэглээтэй
2	25.27	25.73	79.36	22	Бага орлоготой - өндөр хэрэглээтэй
3	41.11	88.20	17.11	35	Өндөр орлоготой - бага хэрэглээтэй
4	45.22	26.30	20.91	23	Бага орлоготой - бага хэрэглээтэй

```
print(cluster_profile)
```

	Age	Annual Income (k\$)	Spending Score (1-100)	Count	\
GMM_Cluster					
0	42.71	55.64	49.37	84	
1	32.69	86.54	82.13	39	
2	25.33	25.10	80.05	21	
3	40.45	88.82	16.00	33	
4	45.22	26.30	20.91	23	

Харьцуулалт

Дүгнэлт

K-Means нь өгөгдлийг хатуу, дугуй хэлбэртэй кластеруудад хуваадаг бол GMM нь Gaussian тархалт ашиглан илүү уян хатан, эллипс хэлбэртэй кластер үүсгэдэг. Манай өгөгдөл дээр GMM нь хэрэглэгчдийн зан төлөвийн тархалтыг илүү бодитой илэрхийлж, overlap бүхий хэсгүүдийг илүү зөв ангилж чадсан