

ICSI263 – Машин сургалт

Гэрийн даалгавар: K-means Clustering ашиглан Mall Customer Segmentation

Өгөгдөл: Mall_Customers.csv | Хэмжээ: 200 мөр × 5 багана

1. Ерөнхий зорилго

Энэ даалгаврын хүрээнд та k-means clustering аргыг ашиглан худалдааны төвийн хэрэглэгчдийг зан төлөвийн хэв маягаар нь сегментчилнэ. Та өгөгдлийг судалж (EDA), Elbow аргаар тохиромжтой кластерын тоо (K)-г сонгож, sklearn сангийн KMeans ашиглан кластерчлал хийж үр дүнг тайлбарлан дүгнэнэ.

2. Даалгавараас гарах үр дүн

- Өгөгдлийн бүтэц, тархалтын үндсэн статистик үзүүлэлтүүдийг гаргаж тайлбарлах
- Elbow аргыг ашиглан K-г сонгох, сонголтоо үндэслэлтэй тайлбарлах
- scikit-learn-ийн KMeans алгоритмыг зөв тохируулан кластерчлал хийх
- Кластеруудыг дүрслэл (plot) болон тайлбар (interpretation)-аар дүгнэх

3. Ашиглах өгөгдөл ба тайлбар

Файл: Mall_Customers.csv. Энэ өгөгдөл нь худалдааны төвийн 200 үйлчлүүлэгчийн суурь мэдээлэл болон худалдан авалтын зан төлөвийг илэрхийлэх оноог агуулна.

Баганын тайлбар:

Багана	Төрөл	Тайлбар
CustomerID	integer	Хэрэглэгчийн давтагдашгүй ID (таних тэмдэг). Моделийн шинжилгээнд заавал ашиглахгүй байж болно.
Gender	category	Хүйс (Male/Female). Кластерчлалд ашиглах бол тоон хэлбэрт хувиргана.
Age	integer	Нас.
Annual Income (k\$)	numeric	Жилийн орлого (мянган ам.доллар).
Spending Score (1-100)	numeric	Худалдан авалтын идэвх/хэрэглээний оноо (1–100).

Тайлбар: K-means нь тоон өгөгдөл дээр ажилладаг тул категори (Gender) баганыг one-hot эсвэл label encoding аргаар хувиргах, мөн feature scaling (StandardScaler) хийхийг зөвлөө.

4. Даалгаврын шаардлага (заавал хийх дэд даалгаврууд)

4.1 Өгөгдлийн талаар статистик мэдээлэл гаргах (EDA)

1. Өгөгдлийг ачаалж, мөр/баганы тоо, өгөгдлийн төрөл (dtypes), алдагдсан утга байгаа эсэхийг шалгана.
2. Тоон багануудын: mean, median, std, min, max, quartile (25%, 50%, 75%) зэрэг статистик үзүүлэлтийг гаргана.
3. Хүйсийн ангиллын тоон тархалтыг (count/ratio) гаргана.
4. Хамгийн багадаа 2 төрлийн дүрслэл хийнэ (жишээлбэл: histogram, boxplot, pairplot, correlation heatmap гэх мэт).
5. Дүгнэлт: Өгөгдлөөс ажиглагдсан сонирхолтой шинж (outlier, skew, боломжит хамаарал)-ийг 3–5 өгүүлбэрээр тайлбарлана.

4.2 Elbow аргаар хамгийн тохиромжтой K-г олох

6. Кластерчлал хийх feature-үүдээ сонгоно (жишээ: Annual Income ба Spending Score; эсвэл Age-г нэмээд 3 feature ашиглаж болно).
7. Feature scaling хийнэ (жишээ: StandardScaler).
8. $K=1 \dots 10$ (эсвэл $1 \dots 15$) хүртэл KMeans ажиллуулж, inertia (SSE/within-cluster sum of squares)-г бүртгэнэ.
9. Inertia–K график (Elbow plot) зурж, 'тохойн цэг'-ийг сонгон K-г тодорхойлно.
10. Сонгосон K-г 2–4 өгүүлбэрээр үндэслэлтэй тайлбарлана.

4.3 sklearn-ийн KMeans ашиглан clustering хийх

11. Elbow-оор олсон K утгаар KMeans загвар үүсгэнэ. (random_state тогтоох, n_init тохируулахыг зөвлөө.)
12. Загвараа сургаж (fit) кластерын шошго (labels_-)г авна.
13. Кластер бүрийн төвүүд (cluster centers)-ийг scale буцааж (inverse_transform) тайлбарлахыг оролдоно (боломжтой бол).
14. Кластеруудыг дүрслэнэ: 2 feature ашигласан бол 2D scatter дээр өнгөөр ялгаж үзүүлнэ. 3+ feature ашигласан бол PCA-гаар 2D болгож дүрслэж болно.
15. Кластеруудын профайлыг тайлбарлана: кластер бүрийн дундаж нас/орлого/оноо (эсвэл сонгосон feature-үүд)-г хүснэгтээр гаргаж, сегмент бүрийг товч нэрлэнэ (жишээ: 'Өндөр орлоготой – өндөр хэрэглээтэй' гэх мэт).

5. Хүлээлгэх материал

Доорх материалыг нэг хавтас болгон (zip) эсвэл sisi -д оруулна:

- Jupyter Notebook (.ipynb) эсвэл Python скрипт (.py) – бүх код ажилладаг байх
- Товч тайлан (1–2 хуудас PDF) – график, хүснэгт, тайлбар, дүгнэлттэй
- Кластерийн дүрслэлийн зураг/графикууд (тайланд шингээсэн байж болно)

6. Үнэлгээний шалгуур (санал болгосон)

Хэсэг

Оноо

Тайлбар

EDA ба статистик	30	Зөв статистик, ойлгомжтой график, дүгнэлт
Elbow арга ба K сонголт	30	Зөв тооцоо/график, K сонголтын тайлбар
KMeans clustering ба тайлбар	35	Зөв хэрэгжилт, дүрслэл, кластер профайл/сегмент тайлбар
Кодын чанар ба тайлангийн бүтэц	5	Цэвэр код, тайлбар, дахин ажиллуулах боломж

7. Зөвлөмж ба анхаарах зүйлс

- CustomerID нь зөвхөн таних тэмдэг тул ихэнх тохиолдолд feature болгон ашиглахгүй.
- K-means нь масштабаас мэдрэмтгий тул scaling хийхгүй бол үр дүн буруу гарах магадлалтай.
- Reproducibility: random_state ашиглаж үр дүнгээ тогтвортой болго.
- Хэрэв та Gender-г ашиглавал one-hot encoding хийгээд бүх feature-үүдийг хамт scaling хийхийг зөвлөө.

8. Академик ёс зүй

Та өөрийн код, тайлбарыг өөрөө бичнэ. Гадаад эх сурвалж ашигласан бол тайландаа заавал ишлэл/линк өгнө. Хуулбарласан ажлыг журамд заасны дагуу үнэлнэ.